说明文档

蒋进

任务一

1创造环境 conda create -n =3.10

[建立的github仓库] https://github.com/jiangjin6896/kaohe.git

必答问题

1.如何判断自己安装的那个版本PyTorch?
先进入已经创立的虚拟环境 conda activate kaohe
然后输入python 然后
import torch
print("PyTorch版本：", torch.**version**) 就可以了
2.遇到的报错：在安装PyTorch过程中 我先去网站https://download.pytorch.org/whl/cu128 下载文件后再在虚拟环境安装 发现报错
问了下AI 发现安装的版本与我创建的虚拟环境中python 版本不匹配
其它问题没有遇到，因为看视频弄的

任务二

1.数据加载 应用with open 语法:with open(file,mode,encoding)分别为文件路径， 模式，文件编码
2.模型构建 手动构建MLP MLP模型基础结构 分为输出层（接收原始数据），隐藏层（提取数据的非线性特征），输出层（输出最终结果），激活函数（引入非线性），前向传播逻辑（定义数据在各层的流动顺序）
模型训练：核心逻辑 前向传播算损失（用模型预测结果，评估预测误差） → 反向传播算梯度（计算参数的梯度（调整方向）） → 优化器更新参数（调整参数，降低损失）最后迭代循环
注：在模型训练中 损失函数用的MSE，为非线性

必答问题

1. 学习率分析（只看黄色线）

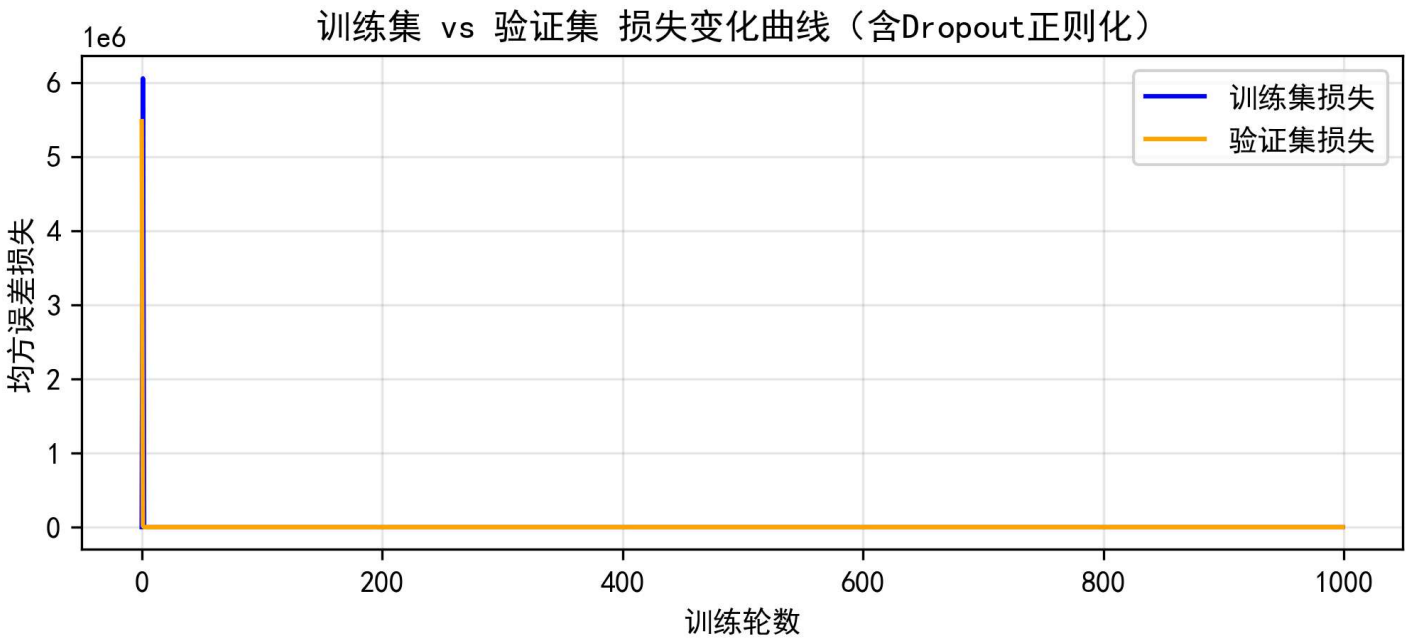

学习率调到1.0时 发生震荡，损失曲线基本上为零

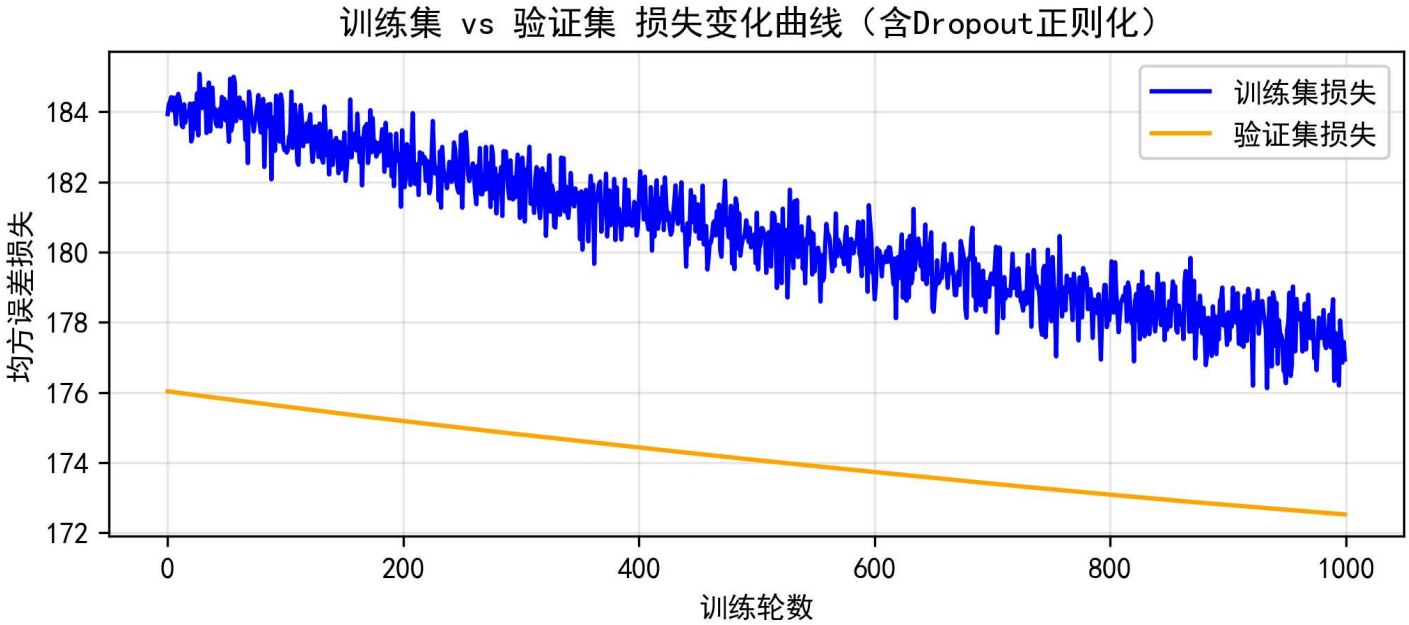

为0.0001时 为一条向下的直线

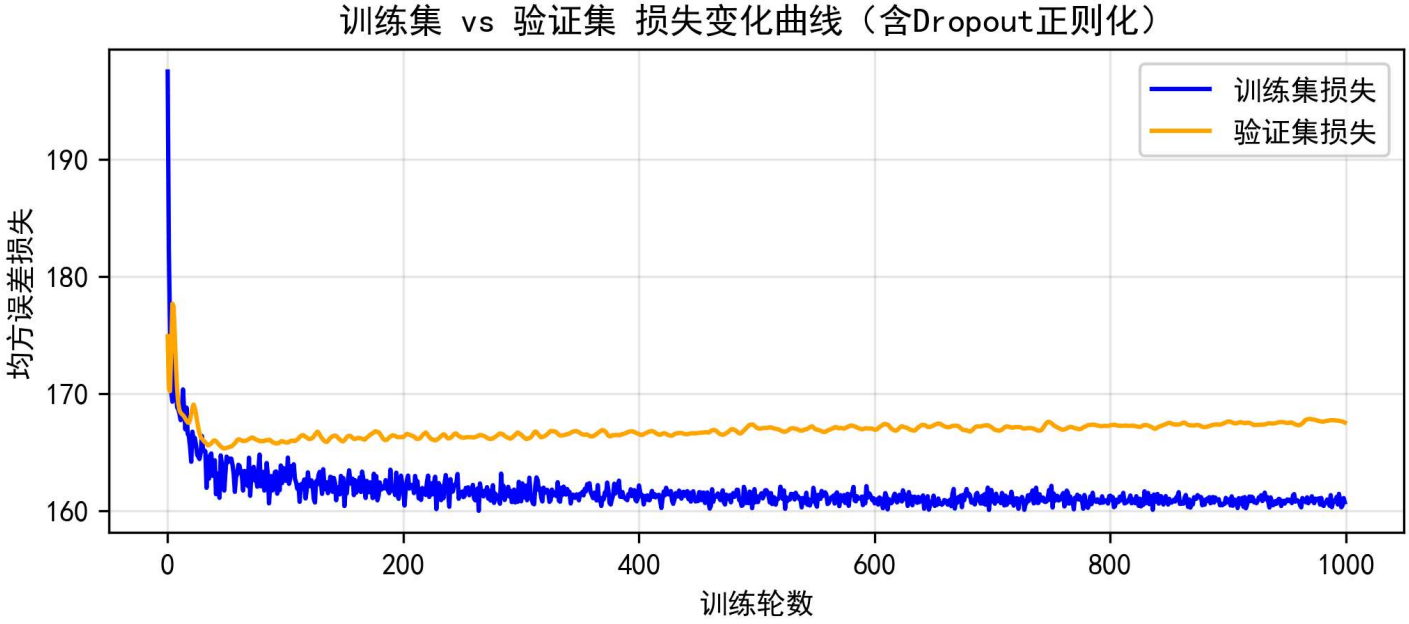

为0.01（AI给的）时整体向下，偶尔向上，有波折，最后趋于平稳
原因：为1.0时： 步长远超梯度，参数调整幅度过大
0.0001时：步长远小于梯度，参数调整幅度不足 参数 “龟速前进”，无法收敛
通俗理解来说就是类似于找宝藏 我的位置在2 宝藏位置在2.5
若学习率调为1.0，相当于每次走1步，永远到不了宝藏位置
若为0.00001，则相当于每步走0.00001，太慢了

2.过拟合判定

过拟合本质：“模型对训练数据的适配度远高于新数据”
相当于 学生考试，背会了考试原题（训练集），能考满分，但换一套新题（验证集）就不会做了
判断方法（AI给的）： 选择的方法1
1.首选：训练 / 验证损失曲线对比（直观、易实现）；
2.辅助：拟合曲线可视化（快速定性）+ 泛化差距 / 损失比（定量写报告）；
3.进阶：k 折交叉验证（复杂任务用）。

判定

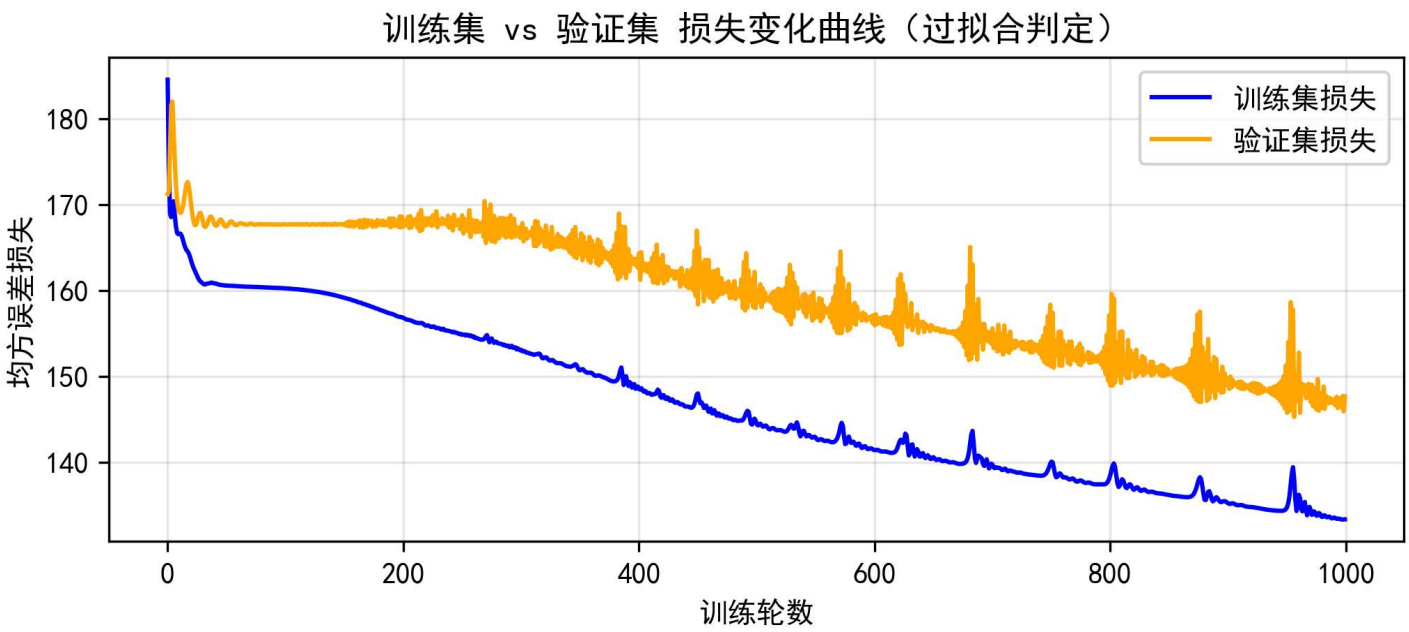

在该图中 训练损失和验证损失的差距随着轮数增加越来越大 所以发生了明显的过拟合

解决方法 （选择Droupt）

一、模型层面（直接改模型结构）

加入 Dropout 正则化
原理：训练时随机 “关掉” 一部分神经元，迫使模型不依赖单一特征，避免死记硬背。
加入 L2 正则化（权重衰减）
原理：在损失函数中加入对参数的惩罚项，限制参数大小，防止模型过度复杂。

二、训练层面（改训练过程）

提前停止训练
原理：在验证集损失最低的轮次停止训练，避免模型 “学过头”。
调整学习率
原理：过大的学习率会导致训练震荡，模型容易过拟合；过小则收敛太慢。

三、数据层面（从数据入手）

增加训练数据量
原理：更多数据能让模型学到更普遍的规律，而不是拟合少量数据的细节。
数据清洗与预处理
原理：去除异常值、重复样本，减少数据中的噪声干扰。
Droupt的构建

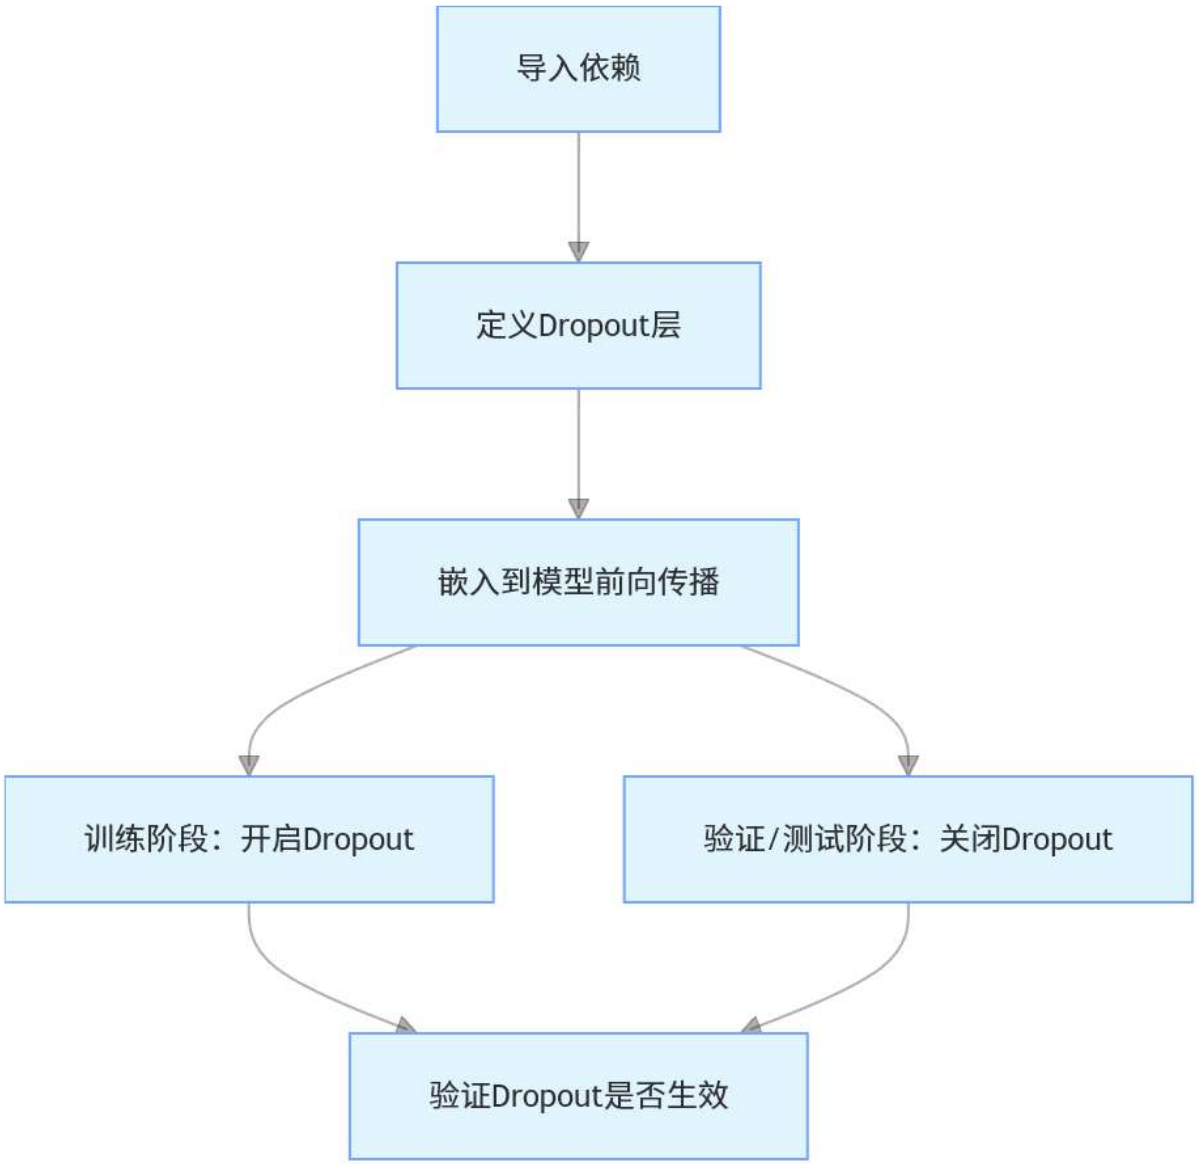

步骤1 导入必备库 首先确保导入 PyTorch 的 Dropout 模块(前提)
步骤2 定义 Dropout 层（位置在模型定义） 其中 参数p作用（训练时神经元的丢弃概率）
步骤3 嵌入Dropout于forword中 位置仅加在隐藏层激活后（千万不能加在输出层） 运行顺序：全连接层 → 激活函数 → Dropout，不能颠倒
原因 在输出层后加 Dropout！会导致预测结果随机波动，验证 / 测试时结果不稳定；把 Dropout 加在激活函数之前，会让激活函数的输入包含大量 0，降低学习效率。
加入Droupt后的结果

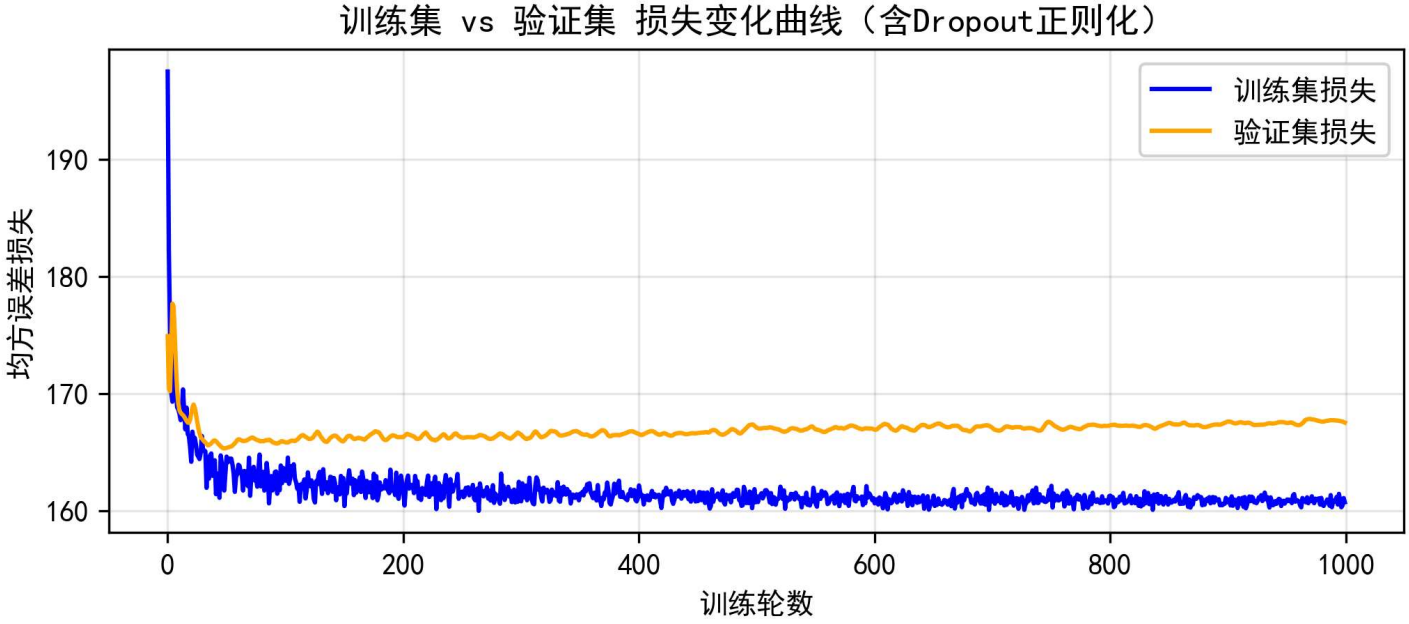
训练集 vs 验证集 损失变化曲线（含Dropout正则化）
训练集损失
验证集损失
均方误差损失
190
180
170
160
0
200
400
600
800
1000
训练轮数

最终拟合结果

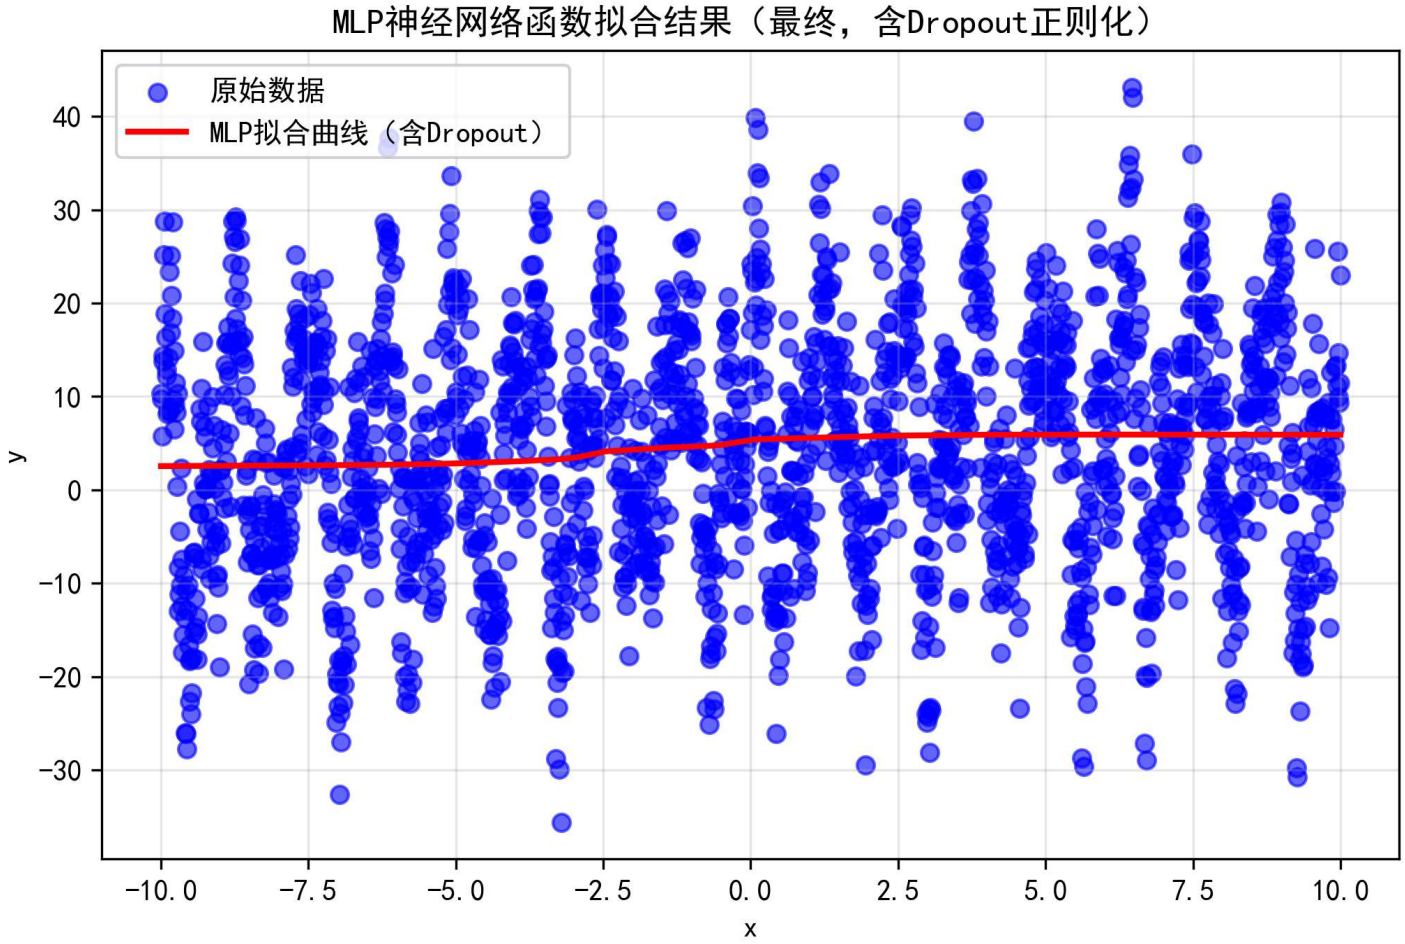
MLP神经网络函数拟合结果（最终，含Dropout正则化）
原始数据
MLP拟合曲线（含Dropout）
y
40
30
20
10
0
−10
−20
−30
−10.0
−7.5
−5.0
−2.5
0.0
2.5
5.0
7.5
10.0
x

任务三 （及格线 CNN）

CNN模型构建及内部原理理解

1.卷积层（就是用来提取局部特征 + 保留空间关系 + 参数共享（高效） + 平移不变性） conv 1/2/3d （分别表示处理几维空间） （, , ,）内容分别为 输入通道数，输出通道数，卷积核大小，填充值
2.池化层 （用来压缩特征图，只留关键信息）
pool(,) 内容分别为 池化核大小，步长
3.全连接层 定义：将输入的一维特征向量（比如卷积层提取后扁平化的特征），通过 “每个输入特征都连接到每个输出特征” 的线性变换，把特征从高维映射到目标维度（比如分类任务的类别数），最终输出任务所需的结果（如分类得分、回归值）。 自己理解（就是输入一个数据，经过线性变换和其他变换，得到最终值）
核心作用：整合全局语义特征 + 转换维度 + 输出最终决策结果
liner(,)： 线性的意思，执行一次线性变换，将维度压缩
函数ReLU 引入非线性让模型学习复杂特征
4.特征扁平化 （把卷积层能处理的 “三维数据”，转换成全连接层能处理的 “一维数据”。） x = x.view(-1, 32 * 8 * 8) 为什么是-1 自动计算这一维度的大小

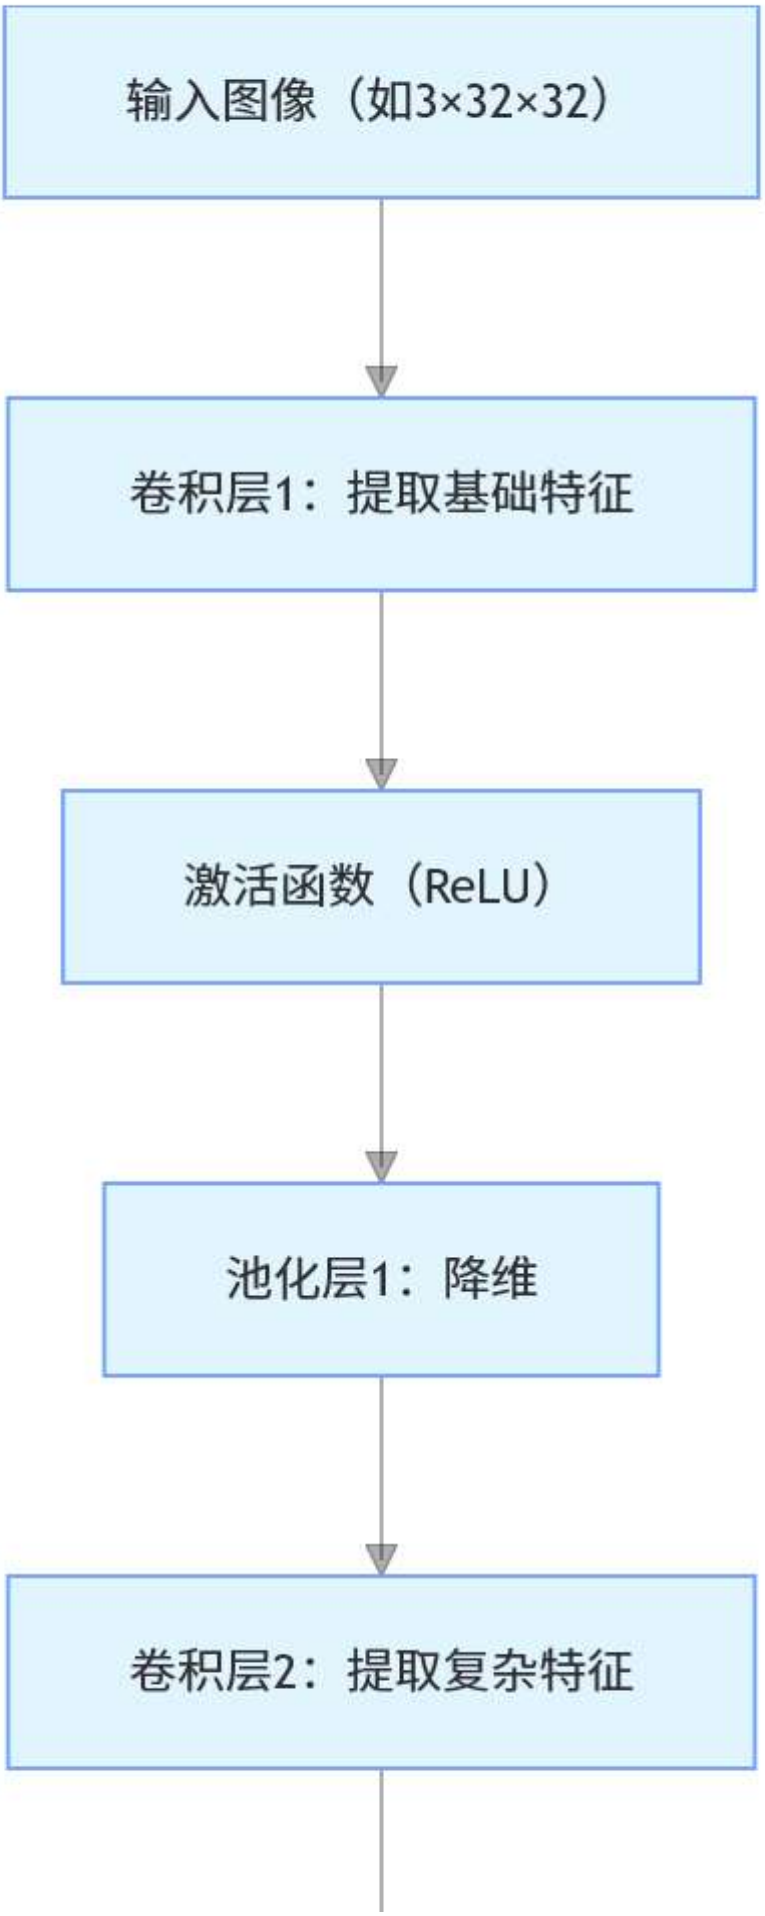
输入图像（如3×32×32）
卷积层1：提取基础特征
激活函数（ReLU）
池化层1：降维
卷积层2：提取复杂特征

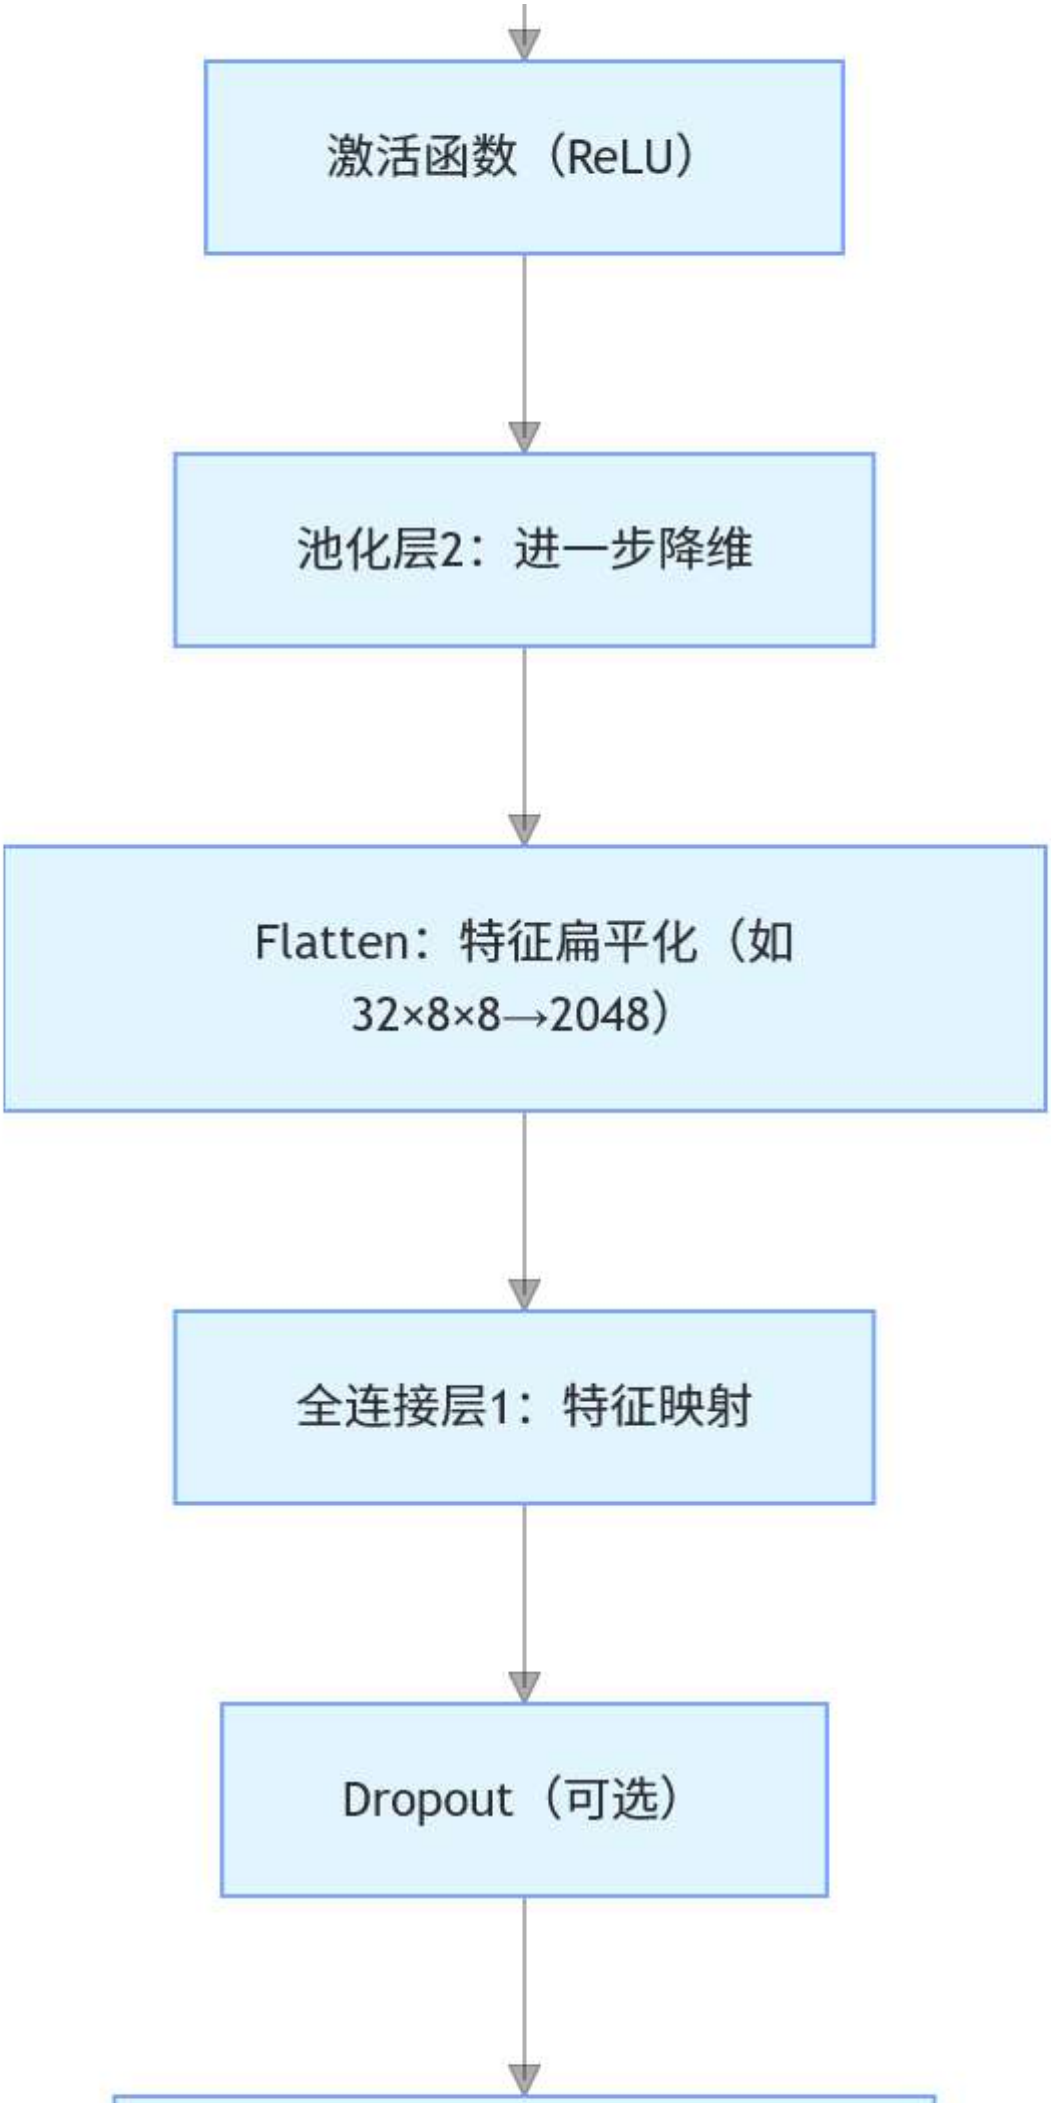
激活函数（ReLU）
池化层2：进一步降维
Flatten：特征扁平化（如32×8×8→2048）
全连接层1：特征映射
Dropout（可选）

全连接层2：输出类别/结果

笔记必答

1.训练日志

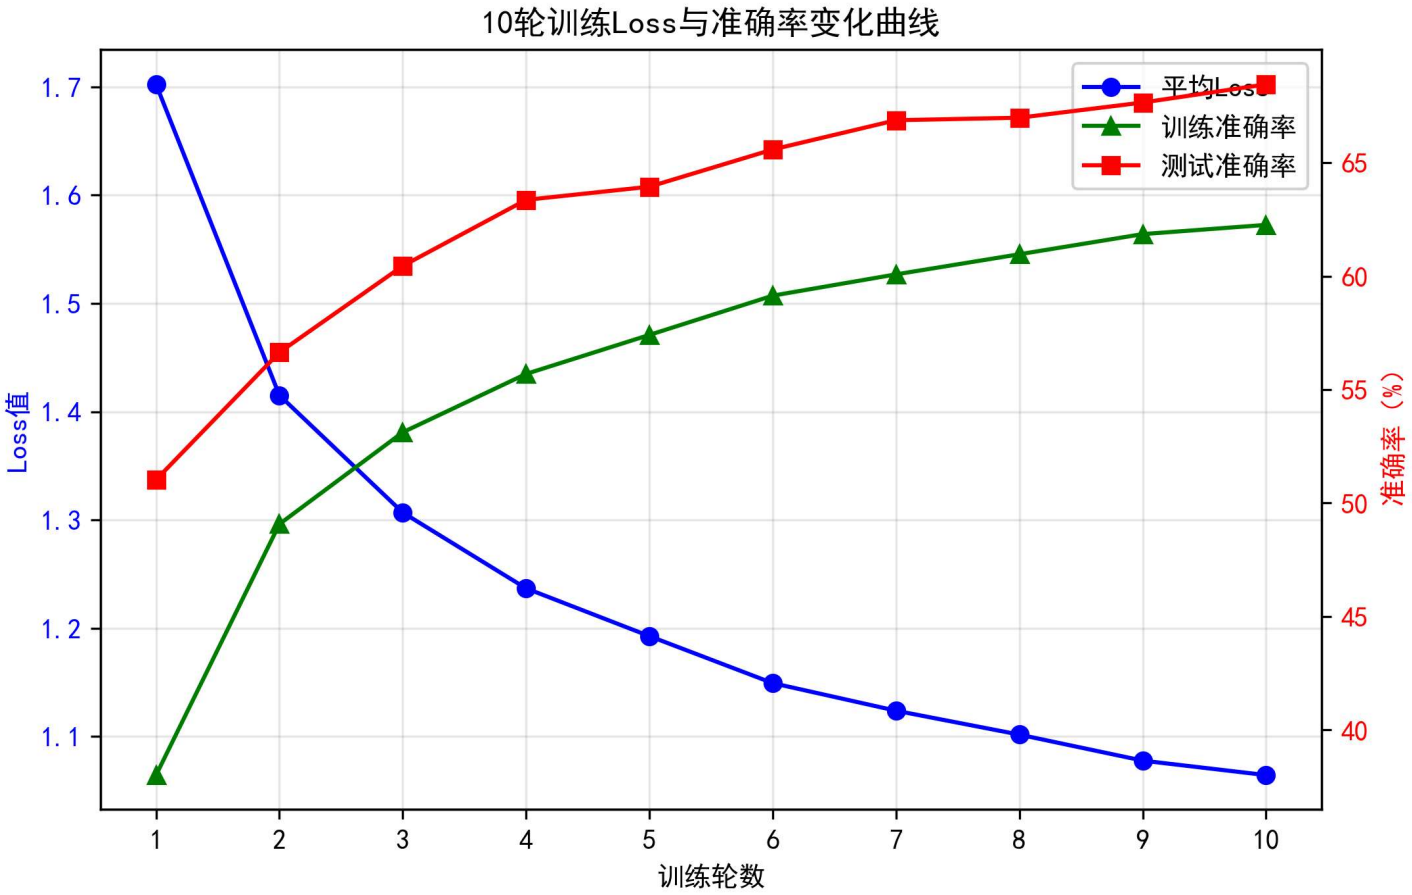

2.Debug复盘:关键维度问题（地点：模型构建）

维度的计算逻辑与顺序

维度运算执行逻辑

原数据	RGB=3	为 32(高度)	X 32(宽度) 的 像素
卷积层1	3→16	32	32
激活函数	16	32	32
池化	16	32→16	32→16
卷积层2	16→32	16	16
激活函数	32	16	16
再次池化	32	16→8	16→8

特征扁平化中 32 X8 X8 由此而来

全连接层1 2048 → 128

2048在扁平化前后区别 全连接层2 128 → 10 → 此处的10是10类事物

前：2048指单张图片特征有2048个 为3维张量

后：指单张图片特征有2048个 但为1维张量

所以，维度填写多少 按这顺序计算即可，不会出错。

（我所填写维度由AI提供的建议）

3.可视化

分类正确的图片示例（8张）

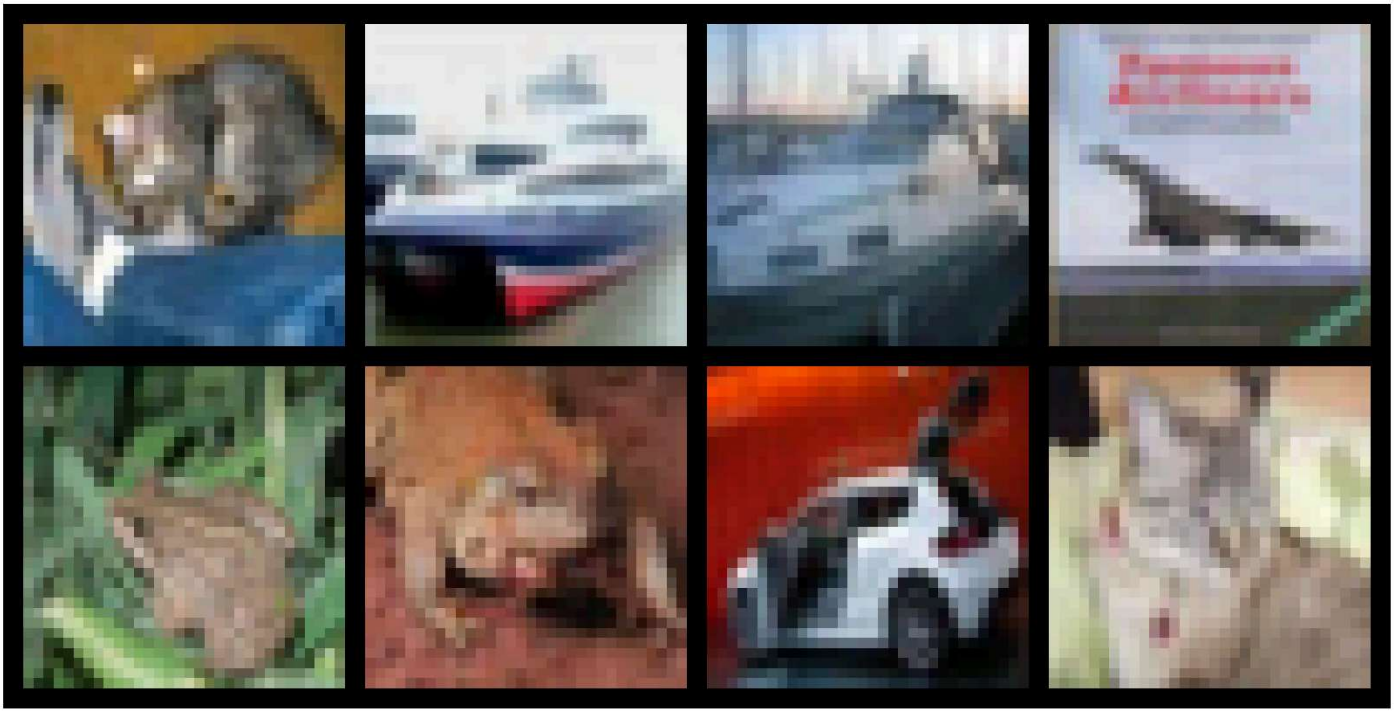

真实标签/预测标签：
第1张：猫/猫　第2张：船/船　第3张：船/船　第4张：飞机/飞机
第5张：青蛙/青蛙　第6张：青蛙/青蛙　第7张：汽车/汽车　第8张：猫/猫

分类错误的图片示例（8张）

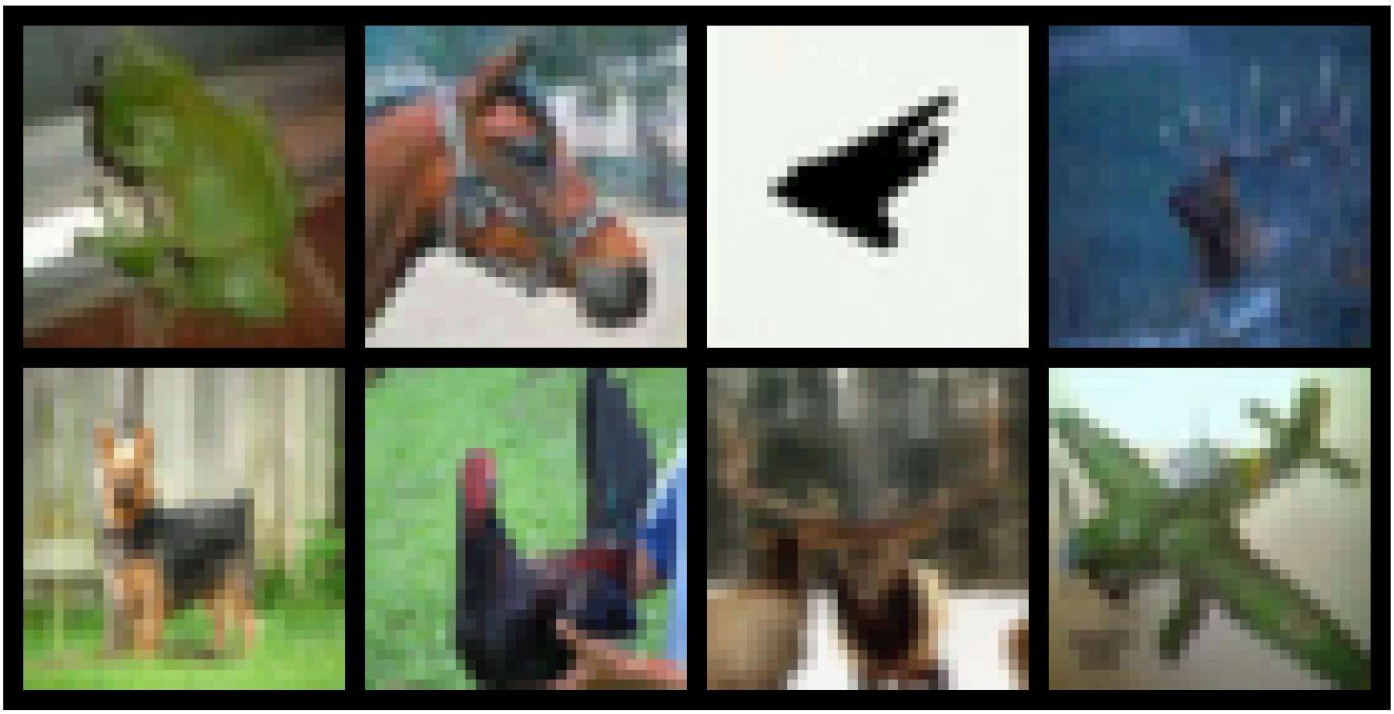

真实标签/预测标签：
第1张：青蛙/鸟类　第2张：马/狗　第3张：飞机/鸟类　第4张：鹿/鸟类
第5张：狗/鹿　第6张：鸟类/鹿　第7张：鹿/猫　第8张：飞机/鸟类

任务四

策略优化 (必做项)

什么是策略优化？ 模型结构不变模型，只优化训练的 “方法和规则” 来提升模型的训练效率、收敛稳定性和最终泛化能力的一系列方法。

学习预热率： 定义：先使用一个很小的学习率，然后逐步提升到你设定的初始学习率，

学习率衰减策略：实现靠近最优解
学习预热+后期衰减
三个部分的作用（类比成一场马拉松）：
1.热身 慢慢加速，避免身体不适应 避免loss曲线暴跌以及不收敛
2.冲刺 实现匀速冲刺向目的地前进 用合适的步长快速学习数据规律，让 Loss 快速下降
3.收尾 调整节奏 精细调整参数，找到 Loss 的 “最小值”，避免错过最优解
Warmup的结构：1.预热参数定义：设定 “预热轮数、基础学习率、增长方式” 2.学习率计算：核心逻辑：根据当前训练轮数，计算本轮应该使用的学习率 3.生效执行 将计算出的学习率更新到优化器中，让本轮训练使用新的学习率

数据混合增强： 定义 通过对训练集中的样本进行线性或非线性混合，生成新的 “虚拟训练样本” 的技术

作用：1.平滑决策边界（让模型综合考虑多种特征，边界更柔和，不会被一点小噪声带偏）
2.扩充数据分布 （数据覆盖范围更广，实现一种物体在多种背景下的情形）
3.提升升模型的泛化能力和鲁棒性 （泛化：面对新数据能力 鲁棒性：抗干扰能力）
结构：数据混合+ 损失计算 +模型更新
数据混合作用：实现新的图片构成不用再找额外图片，让其抓住核心特征，面对新数据时表现更好
损失计算作用：让混合图片有双重特征，避免模型仅偏向一个特征
模型更新：让模型改错，学习，然后提升

结构优化（增加卷积层数量，，引入残差链接）

残差连接 ： 专业定义：让神经网络的某一层的输入，直接加到该层（或后续层）的输出上，使模型学习 “输入到输出的残差（差值）” 而非直接学习 “输入到输出的映射”。 理解（就是让输入的数据不需要行所在层和下面层的计算，进行直接输出
好处：解决梯度消失（避免深层卷积层学不到参数），降低学习难度，提升特征复用
结构：主路径（学残差）+ 捷径路径（做对齐）+ 相加激活
主路径： 卷积+BN+激活+输出 BN：批量归一化，把每一批数据的特征值调整到统一范围，让模型能稳定学习（作用：加速模型训练收敛+缓解梯度消失问题） 注意 最终输出前不要激活函数
捷径路径：把输入 x 的维度（通道数、尺寸）变得和主路径输出一模一样，让它们能相加 结构：1：维度一样时 → 直接恒等映射 结构二：维度不一样时 → 1×1 卷积 + BNs
相加激活：在主路径与相对路径激活后再相加

参数量定义：模型的大脑容量，越高时，能力越强，但对内存和存储要求更高

计算量定义：衡量算力消耗指标，越大时，推理和计算速度越慢，对硬件要求更高

高性能定义： 参数量变大、计算量变高，模型更 “重”、跑得更慢。

轻量化定义： 模型容量变小，可能精度下降，拟合能力变弱。

文档报告

任务五

必答问题

1.可视化

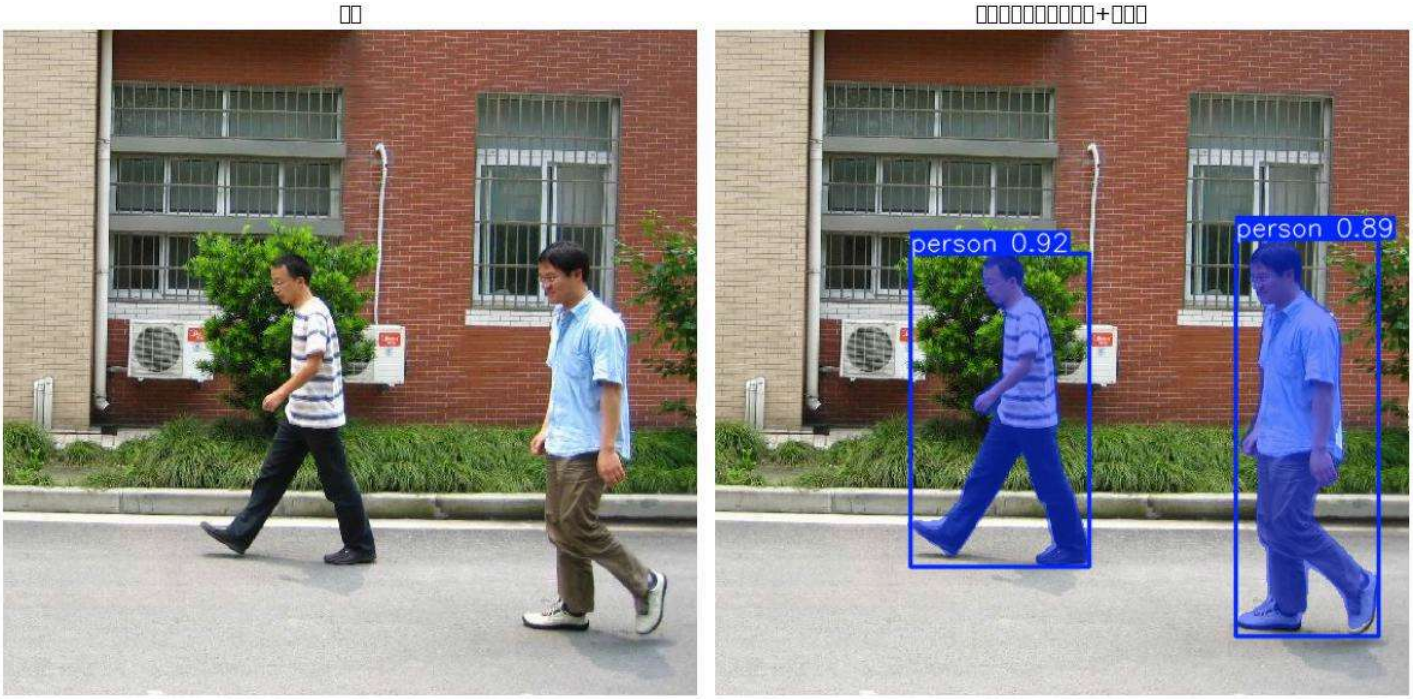

□□

□□□□□□□□□□+□□□

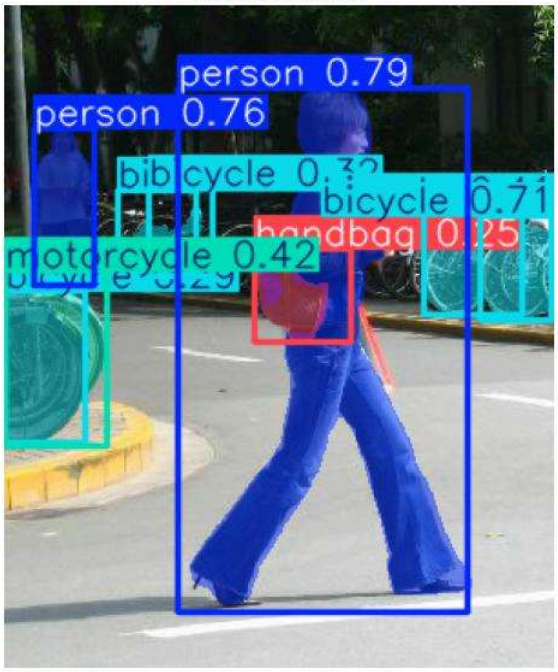

2.思考Mask与Lable的不同
1：层次不同 :一个是像素级 另一个是全局 Mask是Lable更进一步的检测
2.目的不同:Lable是判断属于什么类别，而Mask则判断每个像素属于什么目标且标注了它的位置在哪里

AI使用

1.我觉得AI在解释概念这个环节最有用，应为作为一个什么都不知道的新手，AI通俗易懂讲述了原理和概念，让我得以理解原理
2.在代码API环节失效，在任务五数据下载过程中，因为下载慢，我去问AI快速方法，它提供了阿里的还有清华源以及GitHub上面的东西，全都没有用

核心追问

实话实说，只能完成任务一和文献阅读，最多再加任务二 解释：作为一个完全的新手，我到现在还是缺乏写出完整代码的能力，才入门。概念理解应该能完成一半。